# Définition - Notation

- **V** = **alphabet** = ensemble fini de symboles.
  Ex1: V= {0,1}  Ex2: V={octets}

- Code de **longueur *n*** sur V = sous ensemble de $V^n$.
  - Les éléments du code sont appelés mots de code.

- **Codage** par blocs de source de taille ***k*** $(k < n)$
  - **Φ** : $V^k$ --> $V^n$ : fonction de codage, injective
  - $\Phi(x_1, \ldots, x_k) = y_1, \ldots, y_k, \ldots, y_n$
  - **r** = n – k = nombre de symboles de redondance
  - **Rendement**: **R = k/n** $(0 < R \leq 1)$

- **Code(n, k) sur V** = sous-ensemble de $V^n$ de cardinal $|V|^k$.

# Lien avec entropie: capacité de canal

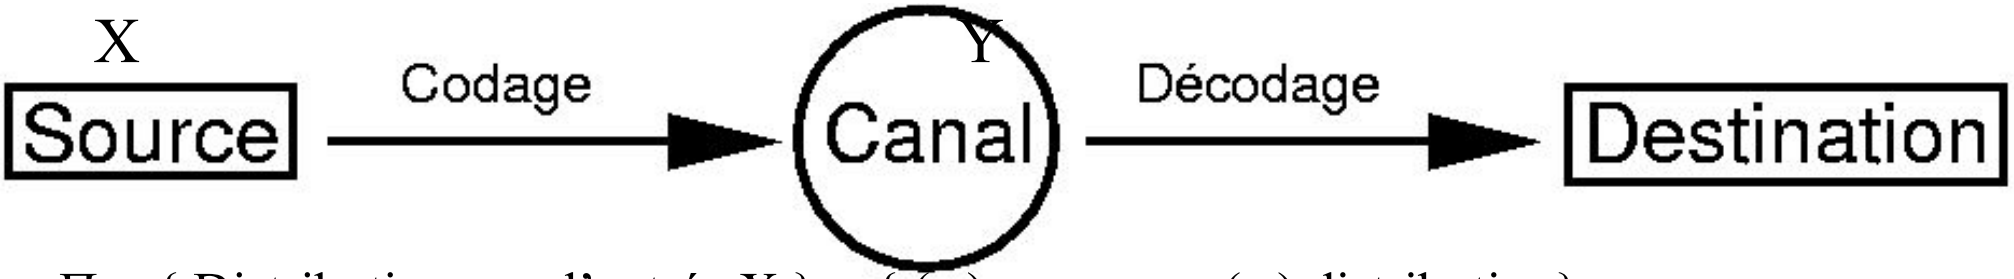


- $\Pi$ = { Distributions sur l'entrée X } = { $(p_i)_{i=1..|V|}$ avec $(p_i)$ distribution}

- $p_{i|k}$ = Prob ( $Y = s_i \mid X=s_k$ ) : caractérise les probabilités d'erreurs lors de la transmission sur le canal sans mémoire.
  - Canal sans erreur ssi ($p_{i,i}=1$ et $p_{i,k\neq i}=0$)

- $P(Y=s_i) = \sum_{k=1..|V|} p_k.p_{i|k}$

- **Déf**: ***Capacité de canal*** : $C = \mathrm{Max}_{p \in \Pi} H(X) - H(X \mid Y)$
  - i.e. ce qu'il reste à découvrir de l'entrée X du canal lorsqu'on connait la sortie Y.

- On a aussi: $C = \mathrm{Max}\ H(Y) - H(Y \mid X)$. Cas extrêmes:
  - $H(Y)=H(Y|X)$ : sortie indépendante de l'entrée.
  - $H(Y \mid X) = 0$ : canal sans erreur.

# Deuxième théorème de Shannon

- **Théorème**: Soit un canal de capacité C. Alors pour tout $\varepsilon>0$:
  $\exists$ un code(n, k) de probabilité d'erreur $<\varepsilon$ ssi $0 \leq k/n < C$.

  *i.e. la capacité de canal C est une limite supérieure au rendement..*

- **Exemple : canal binaire symétrique (BSC).**
  - $C_{BSC} = 1 + p.\log_2 p + (1-p).\log_2(1-p) = 1 - H(p)$
  - Si $p = 0.5$ => $C_{BSC} = 0$ : pas de code correcteur possible.
  - Si $p \neq 0.5$ => il existe un code permettant de communiquer sans erreur
    - Mais son rendement est borné par C.
    - Exemples: p= 0,8 => R < 27% ; p=0,9=> R < 53% ; p=0,99 => R < 92%

- **Problème fondamental du codage:**
  - Construire des codes de rendement maximal pour une longueur n fixée.

# PREMIERS EXEMPLES
## Codes de Parité

- Code ASCII
- Codes de Parité longitudinale et transversale
- Exemples de codes de parité usuels
- Codes de Hamming

# Contrôle de parité

- Une technique de base pour construire un code détecteur
  1. Découper le message en mots de 7 bits $m=[x_0,\ldots, x_6]$
  2. Ajouter aux mots leur parité : $f(m)=[x_0,\ldots, x_6, p]$
     - Le nombre de 1 dans le mot est soit pair (p = 0) soit impair (p = 1)
     - Calculée par : $\mathbf{x_7 = p = \sum_{i=0..6} x_i \bmod 2}$

- Standard n°5 du Comité Consultatif International Télégraphique et Téléphonique (CCITT 5) : le plus populaire, utilisé par exemple aux USA.

| Lettre | Codage de base sur 7 bits | Mot de code avec bit de parité |
|---|---|---|
| a | 1000 001 | 1000 001**0** |
| e | 1010 001 | 1010 001**1** |
| u | 0110 101 | 0110 101**0** |

☺ Permet de détecter tout nombre impair d'erreurs

# « Parités » usuelles pour la simple détection d'erreur

- LUHN10 pour les cartes bleues : dernier chiffre = chiffre de parité
  - Doubler modulo 9 un chiffre sur deux du n°
    - Exemple : 4561 0032 4001 236**c**
    - (4*2%9)+5+(6*2%9)+1+(0*2%9)+0+(3*2%9)+2+ (4*2%9)+0+(0*2%9)+1+ (2*2%9)+3+(6*2%9)
      = 8 +5+ 3 +1+ 0 +0+ 6 +2+ 8 +0+ 0 +1+ 4 +3+ 3 =44
  - Le résultat doit être 0 modulo 10 pour une carte valide
    - Donc c = 10 – (44 % 10 ) = 6 => n° valide = 4561 0032 4001 2366

- Clefs (sécurité sociale, RIB, etc.)
    - Sécu : clef calculée pour le numéro + la clef soit nul modulo 97
    - RIB : clef calculée pour que $(\text{numéro}||\text{clef})_{5+5+11+2 \text{ chiffres}}$ soit nul modulo 97
  - IBAN : lettres + 9 et la somme doit faire 1 modulo 99

- De 1972 à 2077: Code ISBN sur les livres sur 10 chiffres :
  - $\sum_{i=1..10}$ i £ $a_i$ ´ 0 modulo 11

# Code barre EAN-13

- EAN-13 (European Article Numbering)
- Numéro sur 13 chiffres + motif graphique barres noires/blanches

  $c_{12}$ - $c_{11}$ .. $c_6$ - $c_5$ .. $c_0$
- $c_0$ chiffre de parité calculé comme suit:
  - Soient a = mod 10
    etb = $c_{11} + c_9 + c_7 + c_5 + c_3 + c_1$ mod 10
  - Alors $c_0$ = 10 - (a+3b mod 10)
  - Exemple: a= 3+9+1+3+5+7 mod 10 = 8 ; b= 2+9+2+4+6+8 mod 10 = 2; $c_0$ = 10 - (a+3b mod 10) = 10 - 4 = 6
- Le code barre graphique code le même numéro:
  - chaque colonne de 2,31mm code un seul chiffre, par 4 barres de largeur différentes chaque colonne est divisée en 7 barres N/B de largeur élémentaire 0,33 mm
- EAN13 permet de détecter des erreurs mais pas de corriger.
- Depuis 2007: Code ISBN sur les livres=EAN-13: $c_{12}c_{11}c_{10}c_9c_8c_7c_6c_5c_4c_3c_2c_1c_0$
  - Avec pour les livres: $c_{12}c_{11}c_{10}$=978
    - Ex: **978-2-10-050692-7**

      $c_0$=10-[ 9+8+1+0+0+9+3x(7+2+0+5+6+2) mod 10]=10- 3 = 7
- Extensions: code barre bidimensionnel PDF417: permet de coder jusqu'à 2725 caractères, grâce à un code correcteur de Reed-Solomon

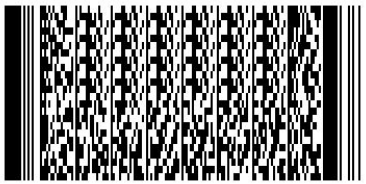

# Parité longitudinale et transversale

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| $a_{00}$ | $a_{01}$ | $a_{02}$ | $a_{03}$ | $a_{04}$ | $a_{05}$ | $a_{06}$ | $P_0$ |
| $a_{10}$ | $a_{11}$ | $a_{12}$ | $a_{13}$ | $a_{14}$ | $a_{15}$ | $a_{16}$ | $P_1$ |
| $a_{20}$ | $a_{21}$ | $a_{22}$ | $a_{23}$ | $a_{24}$ | $a_{25}$ | $a_{26}$ | $P_3$ |
| $C_0$ | $C_1$ | $C_2$ | $C_3$ | $C_4$ | $C_5$ | $C_6$ | N |

1. Mots sur 3*7 = 21 bits
2. Parité par ligne : $P_i$
3. Parité par colonne : $C_j$
4. Parité globale : N

- Détecte 2 ou tout nombre impair d'erreurs
- Corrige 1 erreur
  - Un des $a_{ij}$ est faux : le recalcul de $P_i$ et $C_j$ donne l'emplacement ij
  - $P_i$, $C_j$ et N sont recalculés
- Détecte si il y a 2 erreurs, mais ne permet pas de corriger

## Rendement

- Nombre de bits de message / Nombre de bits transmis
  - Parité : Rendement = 7/8 = 87.5 %
  - Parité long. & transv. : Rendement = 21/32 ≈ 65 %

# Distance de Hamming,
# Taux de correction,
# Bornes supérieures

# Distance d'un code

- Codage: bijection $\mathbf{\Phi}$ : $V^k$ --> C avec C inclus dans $V^n$
  - $\Phi(x_1, \ldots, x_k) = y_1, \ldots, y_k, \ldots, y_n$
- Définitions:
  - **Distance de Hamming** dans $V^n$: $d_H(x,y) = \text{Card}\ \{ i \,/\, x_i \neq y_i \}$
  - **Distance du code C** : $d = \text{Min}\ \{ d_H(x, y) ;\ \forall\ x,y \in C \}$

- A la sortie du canal, on reçoit $z \in V^n$ :
  - Si $\mathbf{z \in C}$ : pas d'erreur détectée; décodage en calculant $\Phi^{-1}(z_1, \ldots, z_n)$.
  - Sinon, $\mathbf{z \notin C}$ : on **détecte qu'il y a erreur(s)** dans les symboles reçus !
    On corrige z en y avec y=mot de C le plus proche de z: $d_H(y,z)=\min_{c \in C} d_H(c, z)$.

- **Théorème** : si C est un code de distance d, alors:
  - on **détecte** jusqu'à **(d-1)** erreurs de symboles par mot de code;
  - on corrige jusqu'à $\lfloor$ **(d-1)/2** $\rfloor$ erreurs de symboles par mot de code.

# Codes équivalents, étendus raccourcis

- C : code (n,k,d) sur V
- Def 1: code **équivalent** : C' obtenu par
  - Permutation de positions dans tous les mots de C
  - Permutation de symboles de V dans tous les mots de C

  C' a même distance et rendement que C

- Def 2: code **étendu** : C' obtenu par ajout d'un chiffre de parité:

  $C' = \{c_1 \ldots c_n\, c_{n+1} \text{ tq } c_1 \ldots c_n \in C \text{ et } c_1 + \ldots + c_{n+1} = 0\}$

- Def 3: code **poinçonné** : C' obtenu en supprimant une position:

  $C' = \text{poinçonné}(C,i) = \{c_1 \ldots c_{i-1}\, c_{i+1} \ldots c_n \text{ tq } c_1 \ldots c_n \in C\}$

  si on poinçonne m positions: $d' \geq d-m$

- Def 4 : code **raccourci** : soit $s \in V$ et $1 \leq i \leq n$ fixés:

  $C' = \text{raccourci}(C,i,s) = \{c_1 \ldots c_{i-1}\, c_{i+1} \ldots c_n \text{ tq } c_1 \ldots c_{i-1}\, s\, c_{i+1} \ldots c_n \in C\}$

  on a $d' \geq d$

# Exemple: Code de Hamming

# Code binaire 1-correcteur

- Code binaire de longueur n:
  - Si il y a 0 ou 1 erreur de bits => n+1 possibilités
- Au moins $r = \log_2 (n+1)$ bits pour coder une erreur possible
- **Code de Hamming**: code ($2^r$-1, k=$2^r$-r-1, d=3)

  $c_1 \ldots c_n$ défini par :
  - Si $i \neq 2^j$ alors $c_i$ est un bit de source
  - Si $i = 2^j$ alors $c_i$ est un bit de contrôle de parité = somme des $c_k$ tel que k écrit en binaire a un 1 en position j
  - Exemple code de Hamming (7,4)

- Détection: si au moins un des bits de parité est erroné
- Correction: on change le bit d'indice la somme des indices des bits de parité erronés

# Code de Hamming

- Code 1-correcteur à nombre de bits ajoutés minimal, $\delta = 3$

 Idée : ajouter un contrôle de parité pour chaque puissance de 2
 b1, b2, b4, b8, b16, etc.

⇒ Cela suffit pour localiser l'erreur !

⇒ $C(n, n-\lfloor \log_2(n) \rfloor -1)$  rendement $\approx 1-\log_2(n)/n$

$$\begin{array}{c} \begin{array}{ccccccc} b_1 & b_2 & & b_4 & & & \end{array} \\ \begin{bmatrix} x_0 & x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & 1 \end{bmatrix} \end{array}$$

⇒ rendements :

- 4/7 ≈ 57 %
- 11/15 ≈ 73 %
- 26/31 ≈ 84 %

…

# Code de Hamming

- Théorème:
  - Les codes de Hamming $C(n, n-\lfloor \log_2(n) \rfloor -1)$ sont de distance 3 :
    - 1-correcteurs
    - Tout mot reçu est corrigé avec 0 ou 1 erreur (code 1-parfait)
  - Tout code binaire linéaire 1-correcteur parfait est un code de Hamming.

- Code de Hamming étendu $C'(n+1, n-\lfloor \log_2(n) \rfloor -1)$
  - Ajout d'un bit de parité = xor des n bits
  - Distance 4 (exercice) donc corrige 1 erreur et 1 effacement.

- Rem.: code binaire **étendu** : obtenu par ajout d'un bit de parité:

$$C' = \{ c_1 \ldots c_n \, c_{n+1} \text{ tq } c_1 \ldots c_n \in C \text{ et } c_1 + \ldots + c_{n+1} = 0 \}$$

**Propriété**: Si d est impaire, alors C' est de distance d'=d+1.

# Application: Code du minitel

- Faible taux d'erreur, mais paquets longs :
  - Code de Hamming + detection paquets
- Source = suite de paquets de 15 octets = 120 bits
- Correction d'1 erreur : Code Hamming(127,120,3) :
  - 7 bits + 1 bit parité pour les 7 bits contrôle = 1 octet
- Détection de paquets: 1octet avec que des 0
  - Si erreur détectée : ARQ
- Total : 17 octets, rendement = 15/17 = 88%

# Plan du cours

- Introduction : Notion de code
- Définition, distance, effacements et erreurs
- Code de Hamming
- **Codes détecteurs d'erreur**
  - LFSR et polynômes.
    Corps de Galois.
  - Codes CRC
  - Propriétés. Applications
- Codes correcteurs : Code linéaire, Reed Solomon
  - Codes cycliques et Reed-Solomon
- Autres codes et applications
  - Rafales d'erreurs. Code CIRC.

# Exemple: contrôle de parité dans TCP

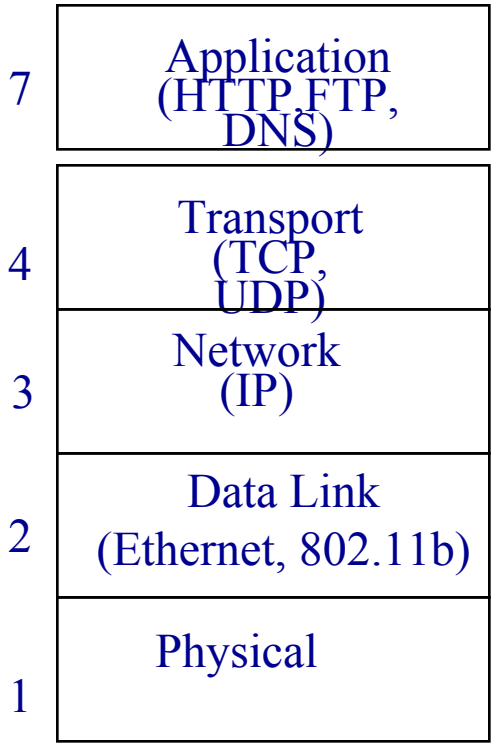


TCP Packet Format

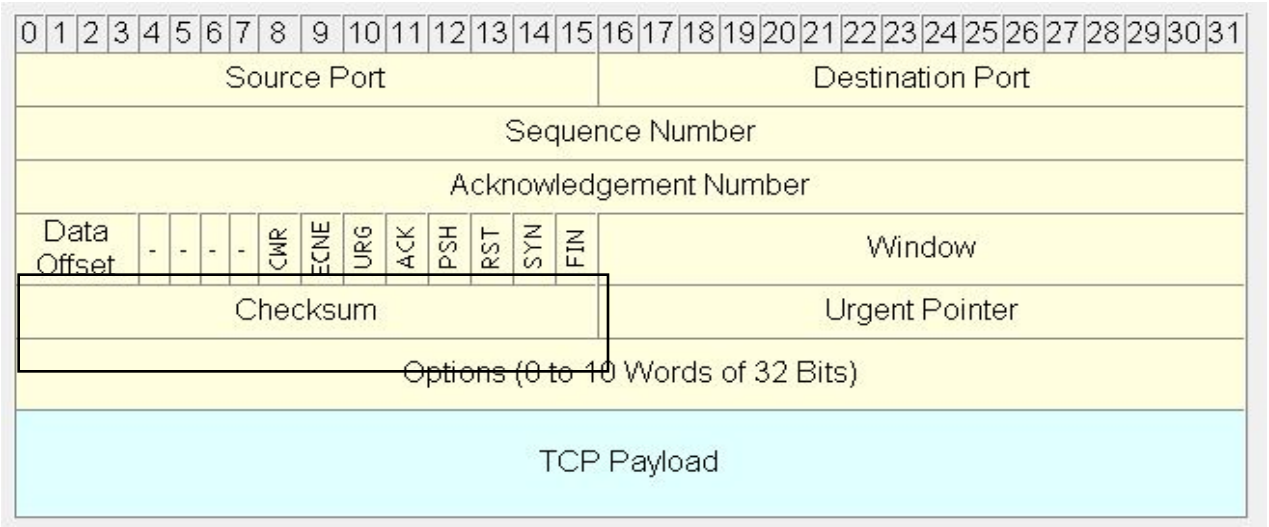


- TCP Checksum :bits de contrôle, calculés par l'émetteur à partir de l'en-tête et des données, et vérifiés lors de la réception.

## Exemple: Ethernet CRC-32

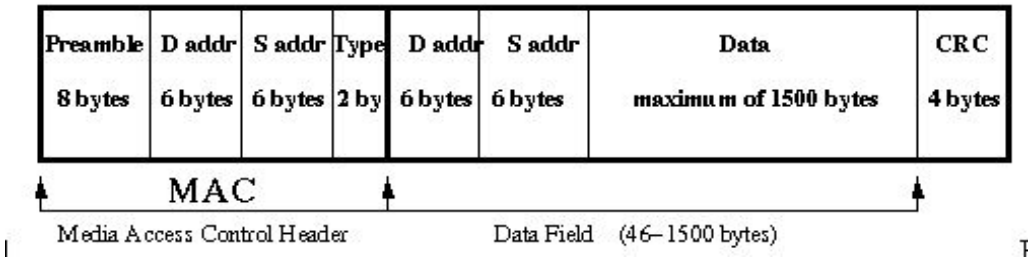

# Linear Feedback Shift Registers (LFSRs)

- LFSR : circuit élémentaire à base de registres à décalage et quelques xor.

- Exemple 4-bit LFSR :

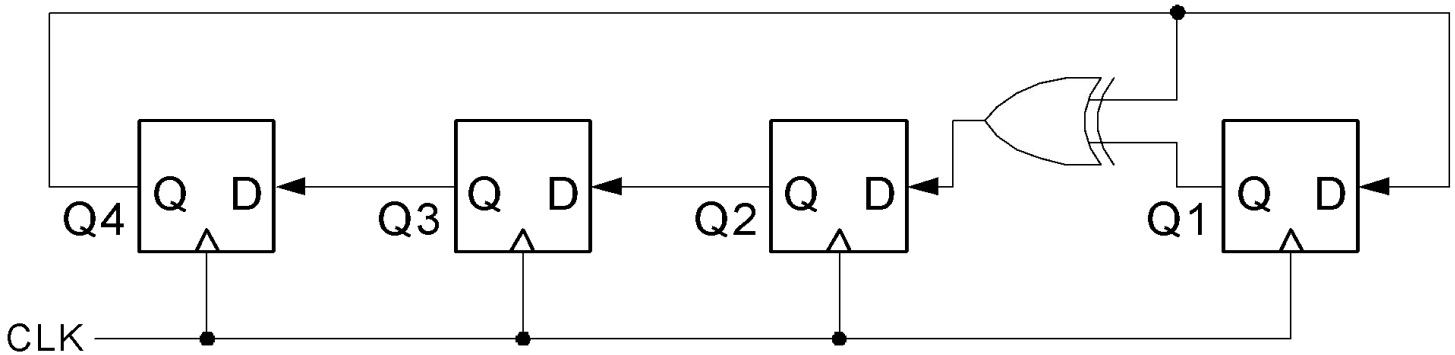


- Avantages:
  - Hardware très simple => opération rapide
  - Rapide (débit élevé) : en général, nombre faible de xors ( 2 !)

- Applications:
  - générateurs pseudo-aléatoires (non cryptographique)
  - compteurs
  - chiffrement (pas seuls ! avec des NLFSRs, des Sbox etc )
  - **détection et correction d'erreurs**

# 4-bit LFSR

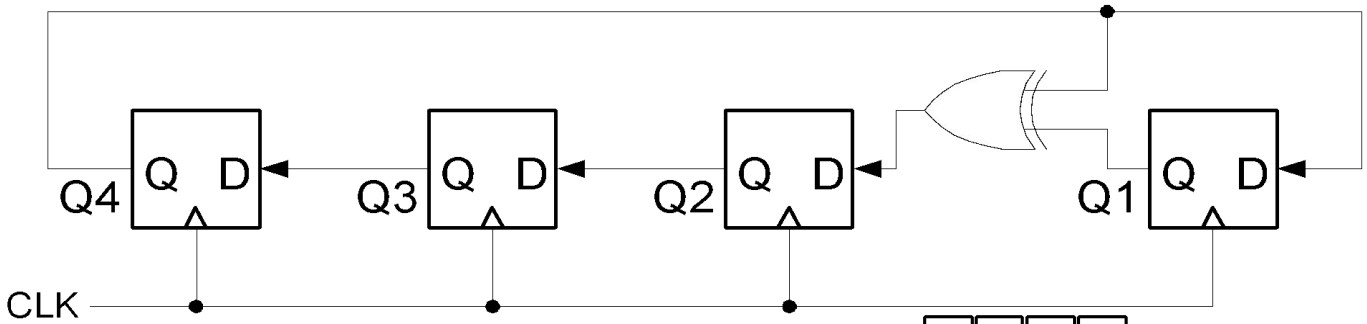


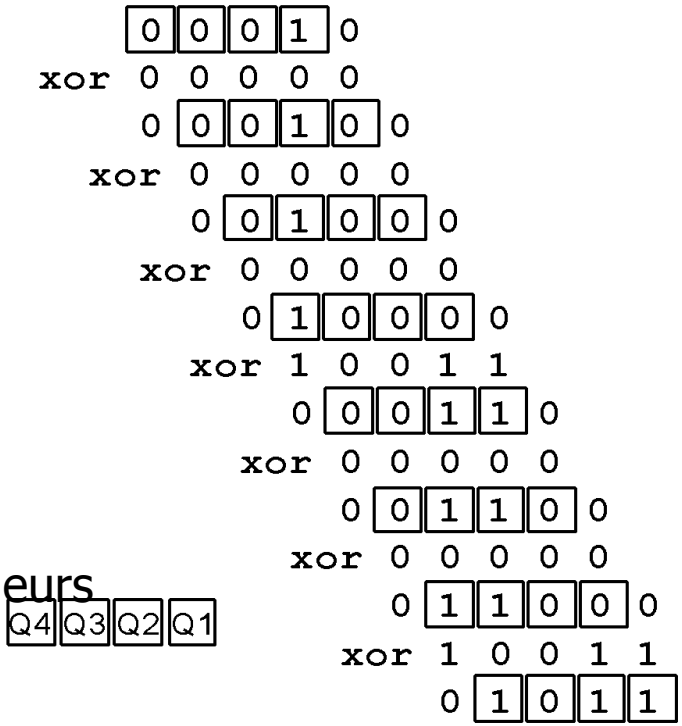


0001
0010
0100
1000
0011
0110
1100
1011
0101
1010
0111
1110
1111
1101
1001
0001

- Etat = valeur des registres [Q4,Q3,Q2,Q1]
- Etat à t+1 = "Left-shift circulaire" état à t suivi de xor avec bit le plus à gauche
- Exemple:
  - Q4(t+1) = Q3(t)
    Q3(t+1) = Q2(t)
    Q2(t+1) = Q1(t) + Q4(t)
    Q1(t+1) = Q4(t)
- En général, avec n bascules, cycle sur $2^n$-1 valeurs différentes non nulles :
  - Exemple: 15 valeurs (NB 0000 est absorbant)
  - générateur pseudo-aléatoire avec une longue période.

# Généralisation: LFSR (dans un corps)

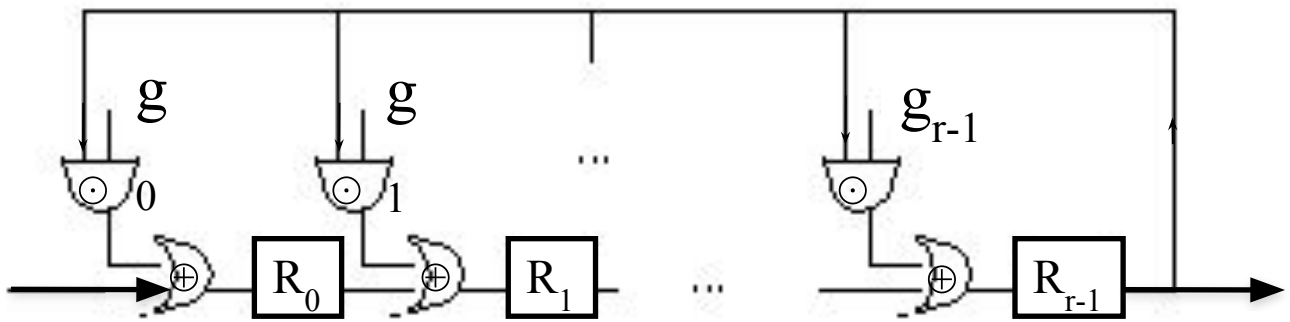


- Valeurs des registres du LFSR :
  - à t : $[R_{r-1}, R_{r-2}, \dots R_0]$
  - à t+1 : $[R'_{r-1}, R'_{r-2}, \dots R'_0]$ avec $R'_i = R_{i-1} + g_i.R_{r-1}$

- Polynôme caractéristique: $g(X) = X^r - g_{r-1}X^{r-1} - \dots - g_0X^0$.

- Notation: K[X] = ensemble des polynômes à coefficients dans K

# Généralisation: LFSR avec opérations dans K. Lien avec polynôme dans K[X]

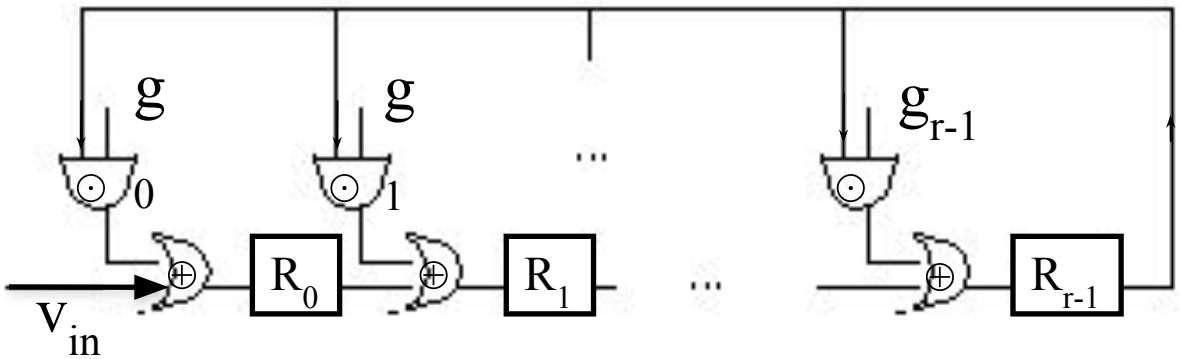


- Valeurs des registres du LFSR :
  - à t : $[R_0, R_1, \dots R_{r-1}]$
  - à t+1 : $[R'_0, R'_1, \dots R'_{r-1}]$
    avec $R'_i = R_{i-1} + g_i.R_{r-1}$
- Polynôme caractéristique :
  - $g(X) = X^r - g_{r-1}X^{r-1} - \dots - g_0X^0$.

- Valeurs des registres du LFSR, vues comme un polynôme :
  - à t : $[R_0, R_1, \dots R_{r-1}]$ : $P_t(X) = R_{r-1}.X^{r-1} + R_{r-2}.X^{r-2} + \dots + R_0.X^0$
  - à t+1: $[R'_0, R'_1, \dots R'_{r-1}]$ :

$$
\begin{aligned}
P_{t+1}(X) &= R'_{r-1}.X^{r-1} + R'_{r-2}.X^{r-2} + \dots + R'_0.X^0 \\
&= (R_{r-2} + g_{r-1}.R_{n-1})X^{r-1} + \dots + (R_{i-1} + g_i.R_{n-1})X^i + \dots + (v_{in} + g_0.R_{n-1})X^0 \\
&= X.P_t(X) - R_{n-1}.g(X) + v_{in}.X^0 \\
&= [\, X.P_t(X) \ \mathit{mod}\ g(X) \,] + v_{in}.X^0
\end{aligned}
$$

- Si K=corps : Reste *division euclidienne polynômiale* par g(X) dans K[X]

# Cas binaire

- $G(X) = X^4 + X + 1$

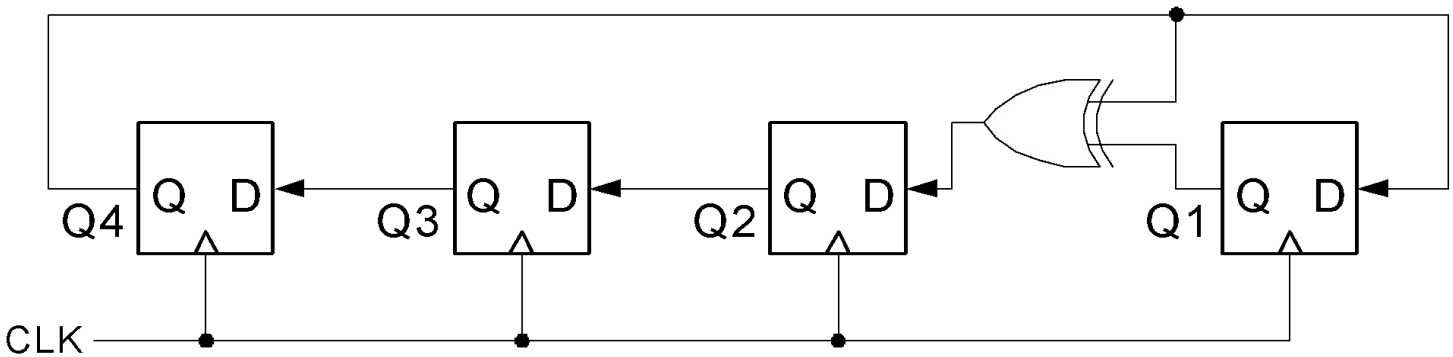

# Plan du cours

- Introduction : Notion de code
- Définition, distance, effacements et erreurs
- Code de Hamming
- **Codes détecteurs d'erreur**
  - LFSR et polynômes.
  - Corps de Galois.
  - **Codes CRC**
  - Propriétés. Applications
- Codes correcteurs : Code linéaire, Reed Solomon
  - Codes cycliques et Reed-Solomon
- Autres codes et applications
  - Rafales d'erreurs. Code CIRC.

# Codes réseaux informatiques : codes CRC (1)

- **CRC** : **cyclic redundancy check** avec r bits de redondance
  Polynome générateur $g(X) = x^r + \Sigma_{i=0..r-1} g_i.x^i$ de degré r sur $F_2$

- **Mots de code** : les multiples de g(X)
  - Source: m=k bits ⇔ m(x) polynome de degré k-1
    - Exemple: m=01101 $m(x) = x+x^2+x^4$
  - Codage: $c = m.x^r - (m.x^r \bmod g) = m.x^r + (m.x^r \bmod g)$
    - On a c multiple de g
    - Redondance r bits ($g_r = 1$)

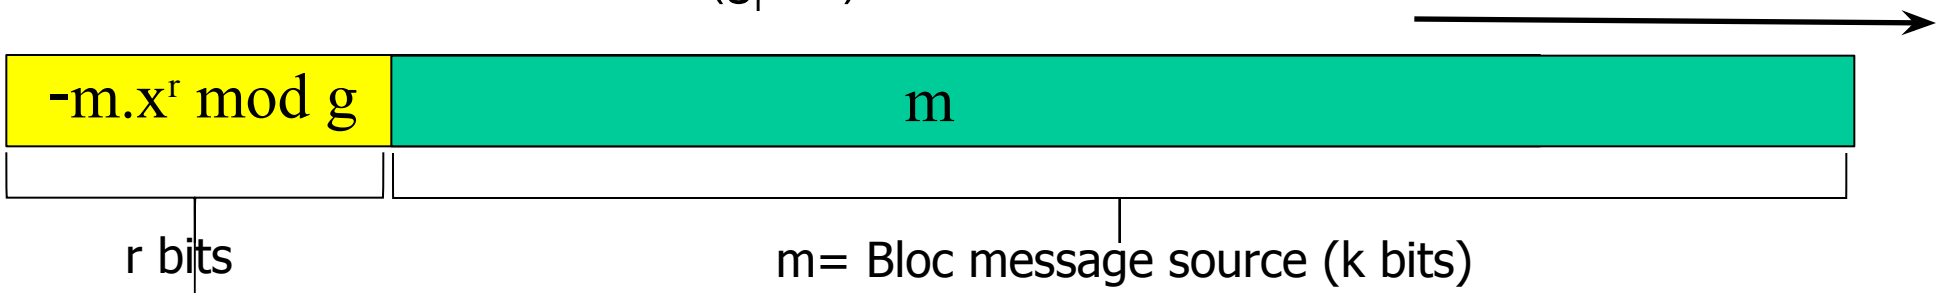


- Décodage : détection d'erreurs
  - Réception de y et vérification que y(x) mod g(x) = 0 !